



**T.C.
BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ
BUCAK TEKNOLOJİ FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ
BİTİRME PROJESİ**

Derin Öğrenme Tekniklerinin İngilizce Öğreniminde Kullanılması

İsmetullah Kayıkçı, Ender Demir

Danışman: Dr. Öğr. Üyesi Elvan Duman

BURDUR, 2024

**T.C.
BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ
BUCAK TEKNOLOJİ FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ
BİTİRME PROJESİ**

Derin Öğrenme Tekniklerinin İngilizce Öğreniminde Kullanılması

İsmetullah Kayıkçı, Ender Demir

Danışman: Dr. Öğr. Üyesi Elvan Duman

BURDUR, 2024

TEŞEKKÜR

Bu araştırma için beni yönlendiren, karşılaştığım zorlukları bilgi ve tecrübesi ile aşmamda yardımcı olan değerli Danışmanım Dr. Öğr. Üyesi Elvan Duman'a teşekkürlerimi sunarım. Deneylerimi yapmam için laboratuvarlarını bana açan ve araştırmalarımnda hiçbir yardımı esirgemeyen değerli hocalarıma teşekkür ederim.

Eğitim hayatımızın her aşamasında beni her yönden destekleyen aileme sonsuz sevgi ve saygılarımı iletiyorum.

Ocak, 2024

İsmetullah KAYIKÇI, Ender DEMİR

İÇİNDEKİLER

	Sayfa
TEŞEKKÜR	i
İÇİNDEKİLER	ii
ŞEKİL DİZİNİ.....	iii
SİMGELER VE KISALTMALAR DİZİNİ.....	iv
ÖZET	v
ABSTRACT	vi
1. GİRİŞ	1
2. GENEL BİLGİLER.....	3
2.1. Flask	3
2.2. Roboflow	3
2.3. MySQL	3
2.4. YOLOv8	3
2.5. Pycharm	4
3. LİTERATÜR TARAMASI	5
4. MATERYAL VE YÖNTEM.....	10
4.1. Materyal.....	10
4.3. Yöntem	10
4.3.1. Nesne Etiketleme ve Model Eğitimi.....	10
4.3.2. Flask Web Uygulaması	12
4.3.3. MySQL (Veritabanı İşlemleri)	14
4.3.4. Gerekli Kütüphaneler.....	16
5. ARAŞTIRMA BULGULARI	17
6. SONUÇ.....	21
6.1. Verileri Listeleyen Tablo	21
6.2. Seslendirme.....	22
6.3. Modelin Performans Grafiği.....	23
7. KAYNAKLAR	24

ŞEKİL DİZİNİ

	Sayfa
Şekil 2.1 YOLO mimarisi.....	4
Şekil 4.1. Veri seti etiketleme	11
Şekil 4.2. Kullanıcı tablosu.....	14
Şekil 4.3. Nesneler tablosu	15
Şekil 4.4. Tespit edilen nesneler tablosu	15
Şekil 5.1. Sınıf dağılımları.....	17
Şekil 5.2. Tespit edilen sırt çantası.....	18
Şekil 5.3. Tespit edilen çoklu nesneler	19
Şekil 5.4. Tespit edilen nesnelerin çeviri ve seslendirilmesi	20
Şekil 6.1. Nesne tespit tablosu	21
Şekil 6.2. Nesne Tespit Sonucu	22
Şekil 6.3. Modelin performansını gösteren grafik	23

SİMGELER VE KISALTMALAR DİZİNİ

GPU	: Graphics Processing Unit
İHA	: İnsansız Hava Aracı
MAKÜ	: Burdur Mehmet Akif Ersoy Üniversitesi
MySQL	: My Structured Query Language, ilişkisel veritabanları üzerinde veri yönetimi, sorgulama ve işlemler için kullanılan bir programlama dilidir.
WEB	: İnternet Ağı
R-CNN	: Region Based Convolutional Networks
SSD	: Single Shot Detector
YOLO	: You Only Look Once

ÖZET

Bitirme Projesi

Derin Öğrenme Tekniklerinin İngilizce Öğreniminde Kullanılması

İsmetullah Kayıkçı, Ender Demir

Burdur Mehmet Akif Ersoy Üniversitesi

Bucak Teknoloji Fakültesi

Yazılım Mühendisliği Bölümü

Danışman: Dr. Elvan Duman

Ocak, 2024

Teknolojinin ilerlemesiyle birlikte, bilgiye erişim ve öğrenme süreçleri, güncel teknolojilerin sağladığı imkanlarla daha da kolaylaşmaktadır. Bu makale, yapay zeka destekli görsel nesne tanıma ve sesli çeviri teknolojilerinin bir araya getirilmesiyle öğrenme deneyimini kişiselleştirilmiş, etkileşimli ve anlam dolu hale getirmeyi amaçlayan bir projeyi tanıtmaktadır. Görsel öğrenme ve ses yoluyla öğrenme üzerine odaklanan bu projede, YOLOv8 modeli kullanılarak görsel algı güçlendirilmiş ve İngilizce dil öğrenimi daha işlevsel hale getirilmiştir.

Projede kullanılan araçlar ve teknolojiler arasında Roboflow platformu, Flask (Python Web Framework), MySQL veritabanı, PIL (Python Imaging Library) ve gTTS (Google Text-to-Speech) gibi önemli unsurlar bulunmaktadır. Roboflow, nesne tespiti modelinin eğitiminden, veri seti oluşturmaya kadar birçok aşamada etkili olmuş, Flask ise web tabanlı kullanıcı arayüzünü geliştirmek için tercih edilmiştir.

Projede kullanılan MySQL veritabanı, kullanıcı bilgilerini, tespit sonuçlarını ve diğer önemli bilgileri depolamak amacıyla kullanılmıştır. Ayrıca, geliştirilen web uygulamasının temel sayfaları ve özellikleri detaylı bir şekilde açıklanmıştır. Örneğin, giriş sayfası, ana sayfa, nesne tespiti sonuçları sayfası gibi temel bölümler kullanıcılara açıklanmıştır.

Makalenin yöntem bölümünde, nesne etiketleme ve model eğitimi süreçleri ayrıntılı bir şekilde açıklanmıştır. Veri seti oluşturma, veri artırma işlemleri, YOLOv8 modelinin eğitimi ve API entegrasyonu gibi adımlar detaylı bir şekilde anlatılmıştır. Ayrıca, Flask web uygulamasının entegrasyonu ve kullanılan diğer kütüphaneler belirtilmiştir.

Son olarak, MySQL veritabanındaki tablolar ve tetikleyicilerle ilgili bilgiler verilmiş, kullanıcılar, nesneler ve tespit edilen nesnelerin detaylarına yer verilmiştir.

Makale, yapay zeka, görsel ve işitsel öğrenme araçlarıyla birleşerek dil öğrenimini güçlendirmeyi amaçlayan geniş bir projenin teknik altyapısı, metodolojisi ve elde edilen sonuçları üzerine detaylı bir inceleme sunmaktadır.

Anahtar Kelimeler: Derin Öğrenme, Nesne Tespit

ABSTRACT

Undergraduate Study

Use of Mobile Technology in Education: The Role of Kindergarten Application in Communication Between Parents and School Administration

İsmetullah Kayıkçı, Ender Demir

**Burdur Mehmet Akif Ersoy University
Bucak Faculty of Technology
Department of Software Engineering**

Supervisor: Dr. Elvan Duman

January, 2024

With the advancement of technology, access to information and learning processes has become increasingly facilitated through the capabilities provided by current technologies. This article introduces a project aiming to personalize, make interactive, and meaningful the learning experience through the integration of artificial intelligence-supported visual object recognition and voice translation technologies. Focused on visual learning and learning through sound, this project enhances visual perception using the YOLOv8 model and makes English language learning more functional.

Among the tools and technologies used in the article are notable elements such as the Roboflow platform, Flask (Python Web Framework), MySQL database, PIL (Python Imaging Library), and gTTS (Google Text-to-Speech). Roboflow has proven effective in various stages, from training the object detection model to creating the dataset, while Flask has been chosen to develop the web-based user interface.

The MySQL database used in the project serves the purpose of storing user information, detection results, and other important data. Additionally, the fundamental pages and features of the developed web application are explained in detail, including the login page, home page, and object detection results page.

In the methodology section of the article, the processes of object labeling and model training are elaborated in detail. Steps such as dataset creation, data augmentation, YOLOv8 model training, and API integration are thoroughly explained. Furthermore, the integration of the Flask web application and other libraries used are specified.

Finally, information about tables and triggers in the MySQL database is provided, detailing users, objects, and detected object specifics. The article presents a comprehensive examination of the technical infrastructure, methodology, and results obtained from a broad project aiming to enhance language learning through the combination of artificial intelligence, visual, and auditory learning tools.

Keywords: Deep Learning, Object Detection

1. GİRİŞ

Teknolojik gelişmeler, öğrenme süreçlerinde radikal değişikliklere yol açarak, bilgiye ulaşma ve anlama biçimlerimizi dönüştürüyor. Bu projenin öne çıkışı, yapay zeka destekli görsel nesne tanıma ve sesli çeviri teknolojilerini bir araya getirerek, sadece bilgi akışını artırmakla kalmayıp aynı zamanda öğrenme deneyimini daha kişiselleştirilmiş, etkileşimli ve anlam dolu hale getirmektir.

Görsel öğrenme, insan zihninin doğal eğilimleri arasında öne çıkar. YOLOv8 modeli, karmaşık nesneleri tanıma konusundaki üstün yetenekleriyle kullanıcılara güvenilir ve hızlı bir öğrenme aracı sunmaktadır. Projemiz, görsel algıyı temel alarak, kullanıcıların gerçek dünyadaki nesneleri tanıma ve anlama yeteneklerini güçlendirmeyi amaçlamaktadır.

Ses yoluyla öğrenme, dil becerilerini geliştirmek açısından önem taşır. İngilizce öğrenimindeki zorluklar göz önüne alındığında, kullanıcılar, tanıdıkları nesnelerin İngilizce isimlerini dinleyerek dil becerilerini hedef alabilirler. Sesli geri bildirim, öğrenme sürecine duysal bir katkı sağlayarak bilginin daha kalıcı hale gelmesine yardımcı olabilir.

Projemiz, dil öğreniminin genel zorluklarına karşı bir çözüm sunma amacını taşımaktadır. Ülkemizde dil öğrenimi genellikle sınırlı bir pratikle sınırlıdır ve bu projede, günlük hayatta karşılaşılan nesnelerin İngilizce isimlerini öğrenme süreci, dil öğrenimini daha işlevsel ve etkili hale getirecek şekilde tasarlanmıştır.

Yapay zeka , eğitim sektöründe devrim niteliğinde değişikliklere yol açmaktadır. Projemiz, öğrenme deneyimini kişiselleştirmek ve kullanıcıların güçlü ve zayıf yönlerini belirleyerek özel bir öğrenme planı oluşturmak amacıyla yapay zekanın potansiyelini kullanmaktadır. Bu, her kullanıcının öğrenme sürecini kendi ihtiyaçlarına göre şekillendirme fırsatı sunar.

Projenin bu karmaşık dizi, öğrenmeyi bir etkileşim ve keşif yolculuğuna dönüştürmeyi amaçlamaktadır. Yapay zeka, görsel ve işitsel öğrenme araçlarıyla birleşerek dil öğrenimini güçlendirmekte, bireylerin öğrenme potansiyelini en üst düzeye çıkarmaktadır. Bu rapor,

projenin bu geniş hedeflerini detaylandırarak, teknik altyapı, metodoloji ve elde edilen sonuçlar üzerinde ayrıntılı bir inceleme sunacaktır.

Bu çalışmalar, mobil uygulamaların ve web tabanlı öğretim araçlarının eğitimdeki potansiyelini vurgulayarak, öğrenci-öğretmen-okul yönetimi arasındaki etkileşimi artırmayı hedeflemektedir. Bu bağlamda, literatürdeki bu önemli çalışmalar, mobil teknolojinin eğitimdeki evrimine dair değerli örnekler sunmaktadır. Gelecekteki eğitim modellerine rehberlik edecek nitelikte olan bu çalışmalar, eğitimde teknolojinin doğru ve etkili bir şekilde entegre edilmesinin önemini vurgulamaktadır.

2. GENEL BİLGİLER

2.1. Flask

Python dilinde geliştirilmiş olan Flask, hafif ve esnek bir web uygulama çerçevesidir. Projeler, Flask kullanarak hızlı bir şekilde web tabanlı kullanıcı arayüzleri oluşturabilir ve arka plandaki işlemleri yönetebilirler. Flask'ın minimal yapısı, hızlı geliştirme imkanı sunarken, esnek modüler tasarımı projelerin ihtiyaçlarına uygun özelleştirmelere olanak tanır. Jinja2 şablon motoru, dinamik içerik oluşturmayı kolaylaştırarak kullanıcı arayüzünü güçlendirir. Flask, geniş bir topluluk desteği ile belgeler, forumlar ve çeşitli eklentilerle kullanıcılara kapsamlı destek sunar.

2.2. Roboflow

Roboflow, nesne tespiti projelerini etkili bir şekilde geliştirmek için kullanılan bir platformdur. Projeler, çeşitli nesne etiketleme işlemleriyle zenginleştirilmiş veri setleri üzerinde çalışabilirler. Otomatik etiketleme özellikleri sayesinde kullanıcılar, hızlı ve doğru veri setleri oluşturabilirler. Roboflow, YOLOv8 gibi güçlü nesne tespiti modellerini entegre ederek yüksek doğruluk ve hızlı performans elde etmeyi sağlar. Ayrıca, bulut tabanlı altyapısı ile esnek bir yönetim imkanı sunar. Roboflow'un geniş veri seti çeşitliliği ve güçlü topluluk desteği, projelerin başarılı bir şekilde geliştirilmesine katkı sağlar.


2.3. MySQL

MySQL, açık kaynaklı bir ilişkisel veritabanı yönetim sistemidir. İşletim sisteminden bağımsız olarak çalışabilir ve genellikle web uygulamaları ve dinamik içerikli sitelerde veritabanı olarak tercih edilir. MySQL, kullanıcıların verileri düzenli bir şekilde depolamalarını, sorgulamalarını ve yönetmelerini sağlar. MySQL, tablolar aracılığıyla verileri düzenler ve SQL adlı sorgu dilini kullanarak veritabanı işlemlerini gerçekleştirir. Bu sistem, veritabanı işlemlerini etkili bir şekilde yönetmek ve web uygulamalarının veri depolama ihtiyaçlarını karşılamak için geniş bir kullanıcı kitlesi tarafından tercih edilmektedir.

2.4. YOLOv8

Derin öğrenme alanında önemli bir yere sahip olan YOLOv8 ,nesne tespiti konusunda etkili ve hızlı bir çözüm sunan bir algoritmadır . YOLO mimarisinin genel yapısı Şekil 2.1'de

görülmektedir. Tek bir geçişte bir resimdeki nesneleri algılayabilme yeteneği, önceki versiyonlara kıyasla daha yüksek hassasiyet ve performans getirir. YOLOv8, derin evrişimli sinir ağları (CNN) kullanarak nesne tespiti işlemlerini optimize eder, bu da nesnelerin sınıflandırılması, konumlarının belirlenmesi ve güven skorlarının hızlı bir şekilde hesaplanmasını sağlar. Geniş bir nesne sınıflandırma yeteneği ve hızlı çalışma özellikleri, YOLOv8'in bilgisayarlı görü ve nesne tespiti uygulamalarında tercih edilmesini sağlar. Bu algoritmanın başarısı, endüstriyel uygulamalardan araştırma projelerine kadar birçok alanda kullanılmasını desteklemektedir.



Şekil 2.1 YOLO mimarisi

2.5. Pycharm

JetBrains'in geliştirdiği PyCharm, Python dilinde yazılım geliştirmek isteyenler için oldukça etkili bir entegre geliştirme ortamıdır. Python geliştiricilerinin ihtiyaçlarına yönelik olarak tasarlanmış olan PyCharm, kullanıcı dostu arayüzü ve zengin özellik seti ile öne çıkar. Otomatik tamamlama, hata ayıklama, versiyon kontrol entegrasyonu gibi fonksiyonlar, yazılım geliştirme sürecini kolaylaştırır. Ayrıca, PyCharm, popüler Python çerçeveleri olan Django ve Flask ile uyumlu çalışarak web geliştirme projelerinde de güçlü bir destek sunar. Proje yönetimi, içerik yönetimi, test otomasyonu gibi araçları içinde barındıran PyCharm, geliştiricilere Python tabanlı projelerini daha hızlı ve verimli bir şekilde hayata geçirme imkanı sağlar.

3. LİTERATÜR TARAMASI

Kazım Hanbay ve Hüseyin Üzen'in (2017) çalışması, nesne tespiti ve takibi alanında yaygın olarak kullanılan güncel yöntemleri ve kütüphaneleri incelemiştir. Geliştirilen yöntemler, farklı karakteristiklere sahip veri setleri üzerinde incelenmiş ve bu yöntemlerin olumlu/olumsuz yönleri tartışılmıştır. Ancak, daha basit problemlerde işlem zamanı ve hesapsal karmaşıklığı daha düşük olan algoritmaların tercih edilebileceği belirtilmiştir. Bu bağlamda, derin öğrenme algoritmalarının nesne takibi ve sınıflandırılmasında uzun bir süre daha kullanılacağı öngörülmektedir.

G. Chandan (2018) Araştırmalarında SSD algoritmasına değinmiştir. SSD algoritmasının temel amacının, çeşitli nesnelerin gerçek zaman görüntülerini algılamak olduğunu belirtmiştir. Bu modelde eğitilen nesne ve üzerinden mükemmel algılama ve izleme sonuçları elde etmiştir. Kusursuza yakın şekilde çalışan bu modelde güvenlik gibi önemli bir konuyu esas alarak okul , hastane ve devlet dairelerinde silahlanmanın tamamen kısıtlandığı yerlerde saldırıları tespit etmek için kullanılabilir.

Fatma Gülşah Tan ve ekibinin (2021) yürüttüğü çalışma, nesne tespiti üzerine derin öğrenme yöntemlerini odaklamıştır. Özellikle, konvolüsyonel sinir ağı temelli ve tekrarlı sinir ağı temelli yöntemlere vurgu yapılmıştır. Araştırmada incelenen çalışmalarda, nesne tespit aşamasında YOLO, Faster R-CNN ve SSD algoritmalarının öne çıktığı belirtilmiştir. Nesne sınıflandırma aşamasında ise tespit edilecek nesnenin özniteliklerine bağlı olarak farklı sınıflandırma yöntemleri kullanılmıştır.Çalışmada dikkat çeken bir diğer nokta, renk ve doku tabanlı yöntemlerin nesne tespitinde daha yüksek başarı oranları elde ettiği gözlemlenmiştir. Bu durum, özellikle nesne sınıflandırma sürecinde görsel özniteliklerin kullanımının önemine işaret etmektedir. Bu tür özelliklere dayalı yöntemlerin, genel başarı düzeyini artırabileceği ve nesne tespiti uygulamalarında etkili olabileceği vurgulanmıştır.

Resul, Berna ve Gürkan'ın (2019) çalışması, derin öğrenmenin özellikle TensorFlow kütüphanesi kullanılarak hareketli nesne tanıma ve takibi üzerindeki etkilerini incelemektedir. Derin öğrenme, görüntü işleme alanında başarılı sonuçlar elde etmiş olup, bu çalışma öğrenme verilerini temsil etme odaklıdır. Özellikle Faster R-CNN modeli kullanılarak nesne takibine odaklanılan çalışma, durağan görüntüler, video görüntüleri ve webcam görüntüleri üzerinde nesne tanıma işlemlerini değerlendirmiştir.Çalışmanın dikkat

eken bir diğ er y  n , literat r taraması sonularına dayanarak geleneksel y  ntemlerin,  zellikle Kalman Filtresi ve Paracak Filtresi gibi, nesne takibinde bařarılı sonular saėlayabileceğini ortaya koymasıdır. Bu, derin  ğrenme dıřındaki y  ntemlerin hala geerli ve etkili olabileceğine iřaret etmektedir. Bu bulgular, farklı y  ntemlerin avantajlarını ve sınırlamalarını anlamak aısından  nemli bir perspektif sunmaktadır..

Kemal T rkaslan ve Fırat Hardala(2022),tek ařamalı nesne tespit modellerinden YOLO ve SSD algoritmaları kullanarak uydu sistemleri vasıtasıyla havadan elde edilen g r nt leri kullanarak g r nt ler  zerindeki nesnelerin tespit edilmesi amacıyla bir alıřma gerekleřtirmiřlerdir. alıřmanın bařarısını her iki algoritmanın performans ve verimlilik aısından analiz etmiřlerdir.

Y. Ma, J. Fang , Q. Zhang (2022), Demir yolları ierisine izinsiz giren yabancı cisimleri tespit etmek ve bu cisimlerin demiryolu kazalarına yol amasını  nlemek iin nesne tespit algoritmalarını arařtırmıřlardır. Kullandıkları en bařarılı y  ntem YOLOv3 olmuřtur. Ortalama algılama doėruluėuyla azaltıřmıř algılama hızıyla %79.2, orijinal aėdan %4.4 daha y ksektir. Sonu olarak kullanılan YOLOv3' n farklı  leklerde yabancı nesne tespiti iin uygun olduėunu ve geliřtirilebileceğini sunmuřlardır.

G. Xiong, J. Qi, M. Wang, C. Wu ve H. Sun insansız hava aralarının ufak detayları seememesinde ki sorundan  t r  farklı metotları kullanarak en uygun olan y  ntemi bulmayı hedeflemiřtir. Bu metotlar YOLO serileri, RetinaNet ve Faster R-CNN řeklinde-dir. T m arařtırmalar ıřıėında GCGE-YOLO'nun daha y ksek hassasiyet saėlarken algılama hızının etkili bir řekilde arttırdığını ve İHA platformu adı altında doėru ve gerek zamanlı nesne tanımayı bařardığı sonucuna vardı. Sonucun bařarılı olmasına raėmen k  k nesnelerin ve olası karmařık sahnelerin olması durumunda tespit sorununun bulunmasıyla daha fazla arařtırmaya ihtiya duyulduėunun da altını izmektedir.

Oėuzhan  nal ve Emre Dandıl (2021),y r tt kleri alıřmada end striyel  retim alanında faaliyetler g steren tesislerin alıřma ortamlarında, alıřanların kiřisel koruyucu donanımlarının kullanımın denetlenmesi ve g vensiz hareketlerin tespiti iin YOLO derin  ğrenme modeli tabanlı bir y  ntem kullanmıřlardır. alıřmada farklı alıřma ortamlarından toplanan video ve g rselleri kullanarak veri seti oluřturulmuřtur. Daha sonra fabrikalarda iřileri kullandığı baret, yelek gibi kiřisel koruyucu ekipmanların tanınması ve doėru

kullanıp kullanmadıkları bu YOLO altyapısı kullanılarak tespit edilmiştir. Bu çalışmada güvenli çalışma ortamlarının kontrolü başarılı bir şekilde sağlandığı ortaya konulmuştur

Mehmet Sevi ve İlhan Aydın(2023),yürüttükleri çalışmada demiryolu hattı ve çevresindeki potansiyel tehlikeleri tespit etmek amacıyla derin öğrenme tabanlı bir yöntem kullanmışlardır. RailSem19 veri seti kullanılarak geliştirilen Yolov8 tabanlı model geliştirmişlerdir. Daha sonra görüntü iyileştirme teknikleri kullanarak veri kümesini çeşitlendirmişlerdir ve eğitilen bu modelde doğrulama aşamasında başarılı bir performans göstermiştir. Son olarak Yolov8 modeli, demiryolu çevresindeki insanları ve araçları başarıyla ayırt edebilmiştir. Bu çalışmanın sonucuna göre nesne tespit çalışmaları demiryolu taşımacılığı güvenliğini arttırmak adına etkili bir yöntem sunmaktadır.

Brunetti vd. (2018), çalışmalarında video gözetimi, insanmakine etkileşimi ve analizi konularında sınıflandırmastratejilerini esas alarak bir anket çalışması sunmuşlardır. Son zamanlarda yaya tespit ve takibinde kullanılan konvolüsyon sinir ağları dahil derin öğrenme metodolojilerinin analiz çalışmalarına yer vermişlerdir. Video izleme, birkaç sensör kullanarak zaman içinde tek veya birden fazla nesneyi bulmayı ve takip etmeyi sağlayan karmaşık bir süreçtir. Hem edinim hem de işleme sistemlerinde dikkate değer bir iyileştirme ihtiyacı nedeniyle,literatürde izleme ile ilgili birçok çalışma bulunabilir. Bu çalışmada yaya tespit ve takip sistemi üzerine bir araştırma European Journal of Science and Technology e-ISSN: 2148-2683 165 sunulmuştur. Analiz edilen çalışmalar, yaya tespit çalışmalarına modern yaklaşımların nasıl araştırılması ve kullanılması gerektiğini vurgulamaktadır. Bununla birlikte, rapor edilen çalışmalar otomatik yaya tespitinde cesaret verici sonuçlar göstermektedir. Ancak daha fazla mimarinin uygulanması ve test edilmesi gerektiğini belirtmişlerdir.

Lu vd. (2017), çalışmalarında uzun kısa süreli bellek ağı ile ardışık çerçeveler arasındaki nesne ilişkisini modellemedeki sorunları ele almışlardır. SSD ağı ve Hungarian algoritması kullanarak geliştirdikleri bu modelde nesnelerin özellikleri arasındaki eşleşme hatalarını en aza indirmişlerdir. Geleneksel video nesnesi algılama yöntemleriyle karşılaştırdıklarında yöntemlerinin daha iyi performans gösterdiğini belirtmişlerdir.

Zhang vd. (2019), çoklu domuz algılama uygulamalarındaki ışık, şekil bozuklukları, tıkanmalar gibi sorunları ele alarak domuzların manuel olarak işaretlenmesini veya fiziksel

olarak tanımlanmasını gerektirmeyen gerçek zamanlı tespit yapan bir model önermişlerdir. Konvolüsyonel sinir ağı tabanlı ve Hungarian algoritması kullanılarak gerçekleştirilen bu model ile ticari bir çiftlikten alınan veri kümesiyle yapılan deneylerin zorlu koşullar altında birden fazla domuzu başarılı bir şekilde algılayıp izleyebildiklerini belirtmişlerdir.

Nawaratne vd. (2020) çalışmalarında, gerçek zamanlı video gözetimi için anomali tespiti ve lokalizasyon zorluklarını ve sınırlamalarını ele almak için artımlı mekânsal-zaman öğrenen (ISTL) modelini önermişlerdir. ISTL, zaman içinde gelişen yeni anomalileri ve normallliği sürekli olarak güncellemek ve ayırt etmek için bulanık kümelenme ile aktif öğrenmeyi kullanan denetimsiz bir derin öğrenme yaklaşımıdır. ISTL, üç karşılaştırma veri seti kullanılarak doğruluk, sağlamlık, hesaplama yükü ve bağlamsal göstergeler üzerinde gösterilmiş ve değerlendirilmiştir. Bu çalışmanın deney sonuçlarına göre gerçek zamanlı video gözetimi için kullanılabilir ve uygun olduğunu belirtmişlerdir.

Ciaparrone vd. (2020), çalışmalarında tek kameralı videolarda çoklu nesne takibi görevini çözmek için derin öğrenme modellerini kullanan çalışmalar hakkında kapsamlı bir anket sunmaktadır. MOT (Multiple Object Tracking- Çoklu Nesne İzleme) algoritmalarında dört ana adım tanımlanmıştır ve bu aşamaların her birinde derin öğrenmenin nasıl kullanıldığına dair derinlemesine bir inceleme sunulmaktadır. Genel bir MOT boru hattını karakterize etmek için dört ana adım gösterilmiştir: algılama, özellik çıkarma, sonsuz hesaplama, ilişkilendirme. Konvolüsyonel sinir ağları uzaysal örüntü çıkarmada en son teknolojiyi oluşturur ve tekrarlayan sinir ağları görüntü sınıflandırma veya nesne tespiti gibi görevlerde kullanılır. Uzun kısa süreli bellek ses sinyalleri, zamansal seri ve metin gibi sıralı verileri işlemek için kullanılır. MOTChallenge, MOTChallenge1 çoklu nesne takibi için en yaygın kullanılan kriterdir

Kanna vd. (2020), çalışmalarında tanıgın sağladığı kimlik işaretlerine dayanarak, suçlu gözetim kameralarından suçluları tespit etmek için derin öğrenme kullanarak yeni bir akıllı metodoloji önermişlerdir. Bu yöntem, nesneyi video verilerinden kişi olarak bulmak için cinsiyet, gömlek deseni ve gözlük durumunu girdi olarak alır. Bu yöntemin performansı, video karesindeki kişiyi tanımlamada %87'lik bir doğruluk sağlamıştır. Li vd. (2020) çalışmalarında, bitki hastalıkları ve zararlılarının zamanında tespiti ve tahıl üretiminin arttırılması için video algılama sistemi kurmuşlardır. Gelecekte gerçek zamanlı bitki hastalıkları ve zararlıları video algılama sistemi ile tespit etmek için özel bir yapıya sahip

derin bir öğrenme tabanlı video algılama mimarisi önermişlerdir. Önce videoyu durağan kareye dönüştürerek çerçeveyi algılama için hareketsiz görüntü detektörüne göndermişler ve son olarak kareleri videoya sentezlemişlerdir. Hareketsiz görüntü detektöründe, çerçeve olarak Faster R-CNN, göreceli olarak bulanık videoları tespit etmek için görüntü eğitim modellerini kullanmışlardır. Ayrıca deneylerde video algılama kalitesini etkili bir şekilde yansıtan bir makine öğrenme sınıflandırıcısına dayanan bir dizi video tabanlı değerlendirme ölçütü önerilmiştir.

Yang vd. (2020), çalışmalarında bulut bağlantılı araçlar ve engelli yayalara yardım gibi akıllı şehir kullanım durumlarını desteklemek amacıyla trafik kavşaklarındaki nesnelerin gerçek zamanlı olarak algılanması ve izlenmesi sorununu ele almaktadır. Bu çalışmada, veriler bulutla geliştirilmiş açık yazılım tanımlı test aracı (COSMOS) ile test edilmiştir. Yayaların güvenilir bir şekilde tespit edilmesinin araçlara göre çok daha zor olduğu bilinmektedir. Bu çalışmada bu sorunun çözümü için tespit algoritması (Yolo, MaskR-CNN ve Tek Çekim Algılama) ve çoklu nesne izleme algoritması (Deep-Sort, Multicut ve Deep) performansına genel bir bakış sunmuşlardır. Çoklu nesne takip doğruluk oranları (MOTA) otomobiller için yaklaşık %73.2 ve yayalar için yaklaşık %2.8'dir. Araçların Avrupa Bilim ve Teknoloji Dergisi e-ISSN: 2148-2683 166 tespiti/izlenmesi için 33.3 ms'lik bir gecikme hedefi belirlemişler ve böyle bir gecikme, 10 km/s hızla hareket eden araçlar için 0.1 metrelik mesafelere karşılık gelen araç konumlarının yararlı bir şekilde örneklenmesini sağlayacağını iddia etmişlerdir. Ayrıca kavşaklardaki yayalar araçlardan 3-10 kat daha yavaş hareket ettiğinden, yaya algılama gecikmelerinin araç gecikmelerinden 3-10 kat daha fazla olmasına izin verilebileceği sonucuna varılmıştır.

4. MATERYAL VE YÖNTEM

Projenin başarılı bir şekilde gerçekleştirilebilmesi için takip edilen adımlar ve kullanılan teknikler aşağıda detaylandırılmıştır.

4.1. Materyal

Proje içerisinde kullanılacak materyaller, tespit edilecek nesnenin fotoğrafları roboflow, coco, kaggle sitelerinden veri setleri elde edilmiştir. Kullanılan verisetleri; akıllı telefon, bozuk para, cüzdan, dizüstü bilgisayar gibi görsellerden oluşmaktadır.

4.2. Aletler ve Cihazlar(Yazılım ve Donanım)

Fotoğraftaki nesneyi algılayabilmesi için web kamerası, ve Python kodlarının derlenebilmesi için Pycharm Community Edition gereklidir. Fotoğrafın yerel ortamda bulunması durumunda kameraya ihtiyaç duyulmayacaktır.

4.3. Yöntem


4.3.1. Nesne Etiketleme ve Model Eğitimi

Projede, veri setini oluşturma ve etiketleme aşamasında Roboflow platformu kullanılmaktadır. Modeli eğitmek adına Colab platformundan faydalanmaktadır. İşte bu süreçlerin ayrıntıları:

Veri Seti Oluşturma:

Roboflow platformu, çeşitli nesne etiketleme işlemleri için kullanıldı. Bu aşamada veriseti; "akıllı telefon", "cüzdan", "dizüstü bilgisayar" ,"bozuk para", "fare(ekipman)", "gözlük", "kalem" ,"kitap", "klavye", "kol saati", "kolye" ,"kulaklık", "makas", "monitör", "pet şişe" ,"priz", "spor ayakkabı", "sırt çantası", "usb bellek" ,"uzaktan kumanda" nesnelere ait 3014 fotoğraf kullanılarak oluşturulmuştur. Etiketleme işlemi Şekil 3.1’de görüldüğü gibi yapılmaktadır.

Bir fotoğrafta tek bir nesnenin etiketlendiği durumlarla birlikte tek fotoğrafta birden fazla nesnenin etiketlendiği durumlar da bulunmaktadır.



Şekil 4.1.Veri seti etiketleme

Veri Artırma İşlemleri:

Derin öğrenme algoritmalarında kullanılacak veri seti yetersiz olduğunda veya daha fazla çeşitlilik gerektiğinde, çoğunlukla veri artırım yöntemleri tercih edilir. Bu bağlamda, görüntü verileri için en yaygın olarak kullanılan veri artırım yöntemleri üzerine bir inceleme yapılmıştır (Yılmaz, 2016).

Veri setinin çeşitliliğini artırmak amacıyla grileştirme, döndürme, bulanıklaştırma, gürültü ekleme, yansıtma gibi veri artırma teknikleri uygulandı. Bu teknikler, modelin farklı ışık koşulları, bakış açıları ve konumlandırmalarla daha iyi başa çıkmasını sağlamak için kullanıldı .

Döndürme: Veri artırımını sağlayan bir yöntemdir; bu yöntem, görüntülerin belirli açılarda döndürülmesiyle elde edilir. Kısaca, döndürme işlemi piksellerin satır ve sütunlarının tersine çevrilmesi olarak da tanımlanabilir.

Yansıtma: Veri artırımını sağlamak için görüntülerin dikey ve yatay olarak ayna yansımalarıyla elde edilen bir yöntemdir. Örneğin, bir araba görüntüsü yatay olarak yansıtıldığında, karşı yönden gelen araba görüntüsü elde edilir.

Gürültü ekleme: Görüntülere çeşitli gürültü türleri ekleyerek, veri artırımını sağlayan ve modelin gerçek koşullarda daha başarılı olmasını hedefleyen bir yöntemdir.

Grileştirme: Bir görüntünün renkli tonlarını gri tonlara dönüştürerek, renksiz bilgi sağlayan bir işlemdir ve genellikle hesaplama gücünden tasarruf sağlar.

Bulanıklaştırma: Görüntüdetaylarını azaltarak veya yumuşatarak, özellikle gürültüyü azaltmak veya belirli özellikleri vurgulamak amacıyla kullanılan bir işlemdir.

Model Eğitimi:

Model YOLOv8 (You Only Look Once) algoritmasıyla, Colab ortamında eğitildi. Colab, GPU kaynaklarını kullanarak modelin hızlı ve etkili bir şekilde eğitilmesine olanak tanıdı.

Modelin eğitimi için eğitim setine 5481, doğrulama setine 579, test setine 608 fotoğraf ayrıldı. Daha sonra bu fotoğraflar 800 pikselde işlenerek modelin eğitimine başlanmaktadır. Eğitim süreci, 25 epoch tercih edilerek tamamlanmaktadır.

4.3.2. Flask Web Uygulaması

Flask web uygulamamız, nesne tespiti yapma yeteneği olan bir arayüz sunan bir kullanıcı arayüzü sunmaktadır. Kullanıcılar, web uygulaması üzerinden bir resim yükleyebilir ve bu resim üzerinde nesne tespiti gerçekleştirebilirler. Tespit edilen nesnenin İngilizcesinin sesli telaffuzuyla birlikte başarı oranı da verilmektedir. Ayrıca, daha önce gerçekleştirilen tespitleri görüntülenebilmektedir.

Flask Framework:

Flask, hafif ve esnek bir Python web uygulama çerçevesidir. Microframework yapısı sayesinde temel özelliklere sahiptir, ancak ihtiyaca göre genişletilebilir.

Roboflow API Entegrasyonu

Roboflow'un güçlü API'si, projemizde nesne tespiti modelini eğitmek ve kullanmak için kritik bir rol oynamaktadır. İlk adım olarak, Roboflow API'ye erişim sağlamak için projemizde kullanmak üzere özel bir API anahtarı edindik. Bu anahtar, güvenli bir şekilde platforma bağlanmamızı ve projemize özel verileri kullanmamızı sağlar.

Daha sonra, projemizin bulunduğu Roboflow çalışma alanına erişerek, belirli bir projeyi ve kullanmak istediğimiz modeli tanımladık. Örneğin, 'fcgvx4oACfbJ4Dxrf5NZ' API anahtarımız ile çalışma alanına bağlandık, ardından 'deneme2-mkqfr' adlı projeyi seçtik ve bu projedeki '7' versiyonunu kullanmak için modeli belirttik.

MySQL Veritabanı Entegrasyonu

Veritabanı, uygulamamızın kullanıcı bilgilerini, tespit sonuçlarını ve diğer önemli bilgileri depolamak için kritik bir role sahiptir. MySQL veritabanı, Flask uygulamamızın arkasındaki bu depolama işlemlerini yönetmek için tercih ettiğimiz bir çözümdür. "db.py" adlı dosyamız, MySQL veritabanıyla etkileşimde bulunmak için gerekli olan yapılandırmaları içerir. Bu yapılandırmalar arasında veritabanı bağlantı bilgileri (host, port, kullanıcı adı, şifre), karakter seti ve diğer önemli ayarlar yer alır. Bu sayede, uygulama, her istekte veritabanına bağlanmaktadır ve gerekli işlemleri gerçekleştirmektedir.

PIL (Python Imaging Library)

PIL, Python Imaging Library, projemizde resim işleme görevlerini hızlı ve etkili bir şekilde gerçekleştirmek için tercih ettiğimiz bir Python kütüphanesidir. Kullanıcıların yüklediği resimleri açma, kaydetme, yeniden boyutlandırma ve döndürme gibi işlemleri kolayca yöneterek, uygulamamızın görsel yönünü güçlendirir. PIL'nin sunduğu pratik fonksiyonlar, kullanıcı deneyimini iyileştirmek ve nesne tespiti süreçlerini desteklemek adına projemize değer katar.

İngilizce Çevirisi

Makalede kullanılan bir diğer yöntem ise, 'nesneler' tablosu aracılığıyla 20 farklı nesnenin Türkçe ve İngilizce karşılıklarını barındıran bir veritabanını entegre etmektir. Bu tablo, her bir nesne için hem Türkçe hem de İngilizce kelimeleri detaylı bir şekilde içermektedir. Kullanıcı, Türkçe bir kelimenin İngilizce karşılığını öğrenmek istediğinde, ilgili kelimenin yanında konumlandırılmış olan "İngilizce Çevirisi" butonuna tıklayarak, bu özel özellikten faydalanabilir ve Türkçe kelimenin İngilizce karşılığını kolayca öğrenme imkanına sahip olabilir. Bu sayede, dil becerilerini geliştirme ve kelime dağarcığını genişletme konusunda kullanıcıya etkili bir destek sunulmuş olur.

gTTS (Google Text-to-Speech)

Uygulamamız, metni konuşmaya dönüştürme işlevselliğini sağlamak amacıyla gTTS (Google Text-to-Speech) kütüphanesinden yararlanmaktadır. Bu kütüphane, metin tabanlı içerikleri sesli bir şekilde sunma yeteneği sunar. Örneğin, nesne adlarının İngilizce çevirilerini kullanarak, uygulama tarafından algılanan nesnelerin isimlerini sesli olarak duyurmak için gTTS kütüphanesi entegre edilmiştir. Bu sayede kullanıcılar, nesnelerin İngilizce isimlerini pratik bir şekilde öğrenebilmektedir.

4.3.3. MySQL (Veritabanı İşlemleri)

Kullanıcılar Tablosu (kullaniciilar)

Uygulama, kullanıcıları “kullaniciilar” tablosunda saklamaktadır. Bu tablo, kullanıcı adı (kullaniciadi), şifre (sifre) ve kullanıcı ID'si (id) alanlarını içermektedir.

	id	kullaniciadi	sifre
▶	1	ender	123
	2	ismet	123
•	NULL	NULL	NULL

Şekil 4.2.Kullanıcı tablosu

Nesneler Tablosu (nesneler)

Uygulama, tespit edilen nesnelerin isimlerini ve İngilizce çevirilerini “nesneler” tablosunda saklamaktadır. Bu tablo, nesne ID'si (id), nesne adı (nesne_adi), çevirisi (ceviri) alanlarını içermektedir.

	id	nesne_adi	ceviri
▶	1	akilli telefon	smartphone
	2	bozuk para	coin
	3	cuzdan	wallet
	4	dizustu bilgisayar	laptop
	5	fare-ekipman-	mouse(equipment)
	6	gozluk	glasses
	7	kalem	pen
	8	kitap	book
	9	klavye	keyboard
	10	kol saati	watch
	11	kolye	necklace
	12	kulaklik	headphones
	13	makas	scissors
	14	monitor	monitor
	15	pet sise	pet bottle
	16	priz	socket
	17	spor ayakkabi	sports shoes
	18	sirt cantasi	backpack
	19	usb bellek	USB flash drive
	20	uzaktan kumanda	remote control
*	NULL	NULL	NULL

Şekil 4.3.Nesneler tablosu

Tespit Edilen Nesneler Tablosu (tespitedilennesneler)

Uygulama, kullanıcıların tespit ettiği nesnelerin bilgilerini “tespitedilennesneler” tablosunda saklamaktadır. Bu tablo, tespit ID'si (id), kullanıcı ID'si (kullanici_id), nesne ID'si (nesne_id), resim yolu (resim), tespit zamanı (tespit_zamani) ve oran (oran) alanlarını içermektedir.

	id	kullanici_id	nesne_id	resim	tespit_zamani	oran
▶	8	1	9	BLOB	2024-01-19 18:37:50	0.74
	9	1	5	BLOB	2024-01-19 18:37:50	0.68
	10	1	12	BLOB	2024-01-20 20:58:04	0.66
	11	1	18	BLOB	2024-01-20 23:14:52	0.83
*	NULL	NULL	NULL	NULL	NULL	NULL

Şekil 4.4.Tespit edilen nesneler tablosu

Triggers (Tetikleyiciler)

Ayrıca, veritabanında kullanılan trigerler (tetikleyiciler) ile belirli kontroller yapılmaktadır. Örneğin, aynı nesnenin tekrar tespit edilmesi durumunda bu bilginin veritabanına kaydedilmemesi sağlanmaktadır.

4.3.4. Gerekli Kütüphaneler

Numpy: Numpy, Python dilinde sıkça kullanılan bir bilimsel hesaplama ve veri analizi kütüphanesidir. Bu kütüphane, özellikle multidimensional diziler ve matrisler gibi veri yapıları için güçlü destek sunar. Numpy'nin temel amacı, bilimsel hesaplamalarda etkili bir şekilde çalışabilen ve büyük veri setleri üzerinde hızlı işlemler gerçekleştirebilen veri yapıları sağlamaktır.

Matplotlib: Matplotlib kütüphanesi veri görselleştirme için kullanılan bir grafik kütüphanesidir. Güçlü, esnek ve çeşitli grafikler oluşturulabilir. Model doğruluğunu görselleştirmek için kullanılabilir.


Tensorflow: Google tarafından geliştirilen , açık kaynak kodlu olan bir makine öğrenimi ve yapay zeka kütüphanesidir. Tensorflow, derin öğrenme modellerinin oluşturulması, eğitilmesi ve daha sonrasında kullanması için geliştirilmiş bir kütüphanedir. Projede nesne tespiti için kullanılmaktadır.

Keras: Tensorflow üzerinde çalışan yüksek seviyeli bir makine öğrenimi kütüphanesidir. Derin öğrenme modelleri oluşturmak ve eğitmek için popüler bir araçtır.

Scikit-learn: Sınıflandırma, kümeleme, regresyon gibi farklı makine öğrenme algoritmalarını birleştiren Python kütüphanesidir. Makine öğrenimi için popüler olarak kullanılmaktadır. Projede nesnelerin sınıflandırılması için kullanılmaktadır.

5. ARAŞTIRMA BULGULARI

Sınıf Dengesi, projemizin başarı kriterlerinden biridir ve bu bağlamda modelin sınıflar arasındaki doğruluk oranlarına dikkat edilmiştir. Şekil 5.1'de görüldüğü üzere, modelin sınıflar arasındaki dağılımını gösteren "Class Balance" grafiği bulunmaktadır.



Şekil 5.1.Sınıf dağılımları

En iyi tespit edilen nesneler, özellikle "spor ayakkabı" ve "klavye" gibi sınıfların eşit dağıldığı gözlemlenmiştir. Bu sınıfların yüksek doğruluk oranları, modelin bu nesneleri başarılı bir şekilde tanıdığını ve projenin belirli alanlarda güçlü olduğunu göstermektedir. Ancak, "usb bellek" ve "kolye" gibi düşük doğruluk oranına sahip sınıfların üzerinde odaklanarak modelin geliştirilmesi, genel doğruluk seviyesinin arttırılmasına katkı sağlayabilir. Bu sınıflardaki performansı iyileştirmek, modelin genel kullanılabilirliğini ve güvenilirliğini artırabilir. Nesnenin gereğinden fazla tespit edilmesi veya az tespit edilmesi modelin dengesini olumsuz şekilde etkilemiştir.



Şekil 5.2.Tespit edilen sırt çantası

Kullanıcı tarafından yüklenen fotoğraf üzerinde gerçekleştirilen nesne tespit taraması, YOLOv8 algoritması tarafından yönetilmektedir. Bu algoritma, geniş bir veri setinde önceden etiketlenmiş nesneleri tanıma yeteneğine sahiptir. Kullanıcının talep ettiği özel bir nesne, bu durumda sırt çantası, tespit edildiğinde, algoritma tarafından otomatik olarak çerçeve içerisine alınır. Ardından, kullanıcıya bu tespiti göstermek amacıyla belirli bir görsel arayüz kullanılır. Bu süreç, kullanıcının yüklediği fotoğraftaki nesneyi belirleyerek, sırt çantasını öne çıkaran bir işlevselliği içerir. Yapay zeka algoritmaları, bu tür görevleri hızlı ve etkili bir şekilde gerçekleştirme kapasitesine sahip olduklarından, nesne tespit taraması uygulamalarında yaygın olarak kullanılmaktadır. Bu teknoloji, kullanıcı deneyimini zenginleştirerek ve istenilen nesneleri belirleyerek bilgiye hızlı erişimi destekler.



Şekil 5.3.Tespit edilen çoklu nesneler

Kullanıcı tarafından yüklenen fotoğrafta birden fazla nesneler olabilir.YOLOv8 modeli geniş yetenekleri arasında aynı resimde birden fazla nesne tespit taraması yaparak çoklu nesneleri tespit edebilmektedir. Şekil 5.3’de kullanıcının yüklediği fotoğrafta monitör, klavye, fare-ekipman nesnelerini başarılı bir şekilde tespit ederek kullanıcıya göstermektedir. Aynı şekilde veriseti içerisinde telefon nesnesi bulunmasına rağmen cep telefonunu çerçeve içerisine alıp kullanıcıya göstermemektedir. Bunun sebebi cep telefonu nesnesini tanınamasından kaynaklı olmayıp, doğruluk tahmin oranının %50 altında olmasından kaynaklanmaktadır. Kullanıcıya gösterilen nesnelerin başarılı olması için %50 ve üzerindeki doğruluk tahmin orana sahip nesneleri göstermektedir.

Nesne Tespiti Sonucu

klavye - Güvenilirlik: 0.81

İngilizce Karşılığı

İngilizce Çevirisi: keyboard **Seslendir**

fare-ekipman- - Güvenilirlik: 0.75

İngilizce Karşılığı

İngilizce Çevirisi: mouse(equipment) **Seslendir**

monitor - Güvenilirlik: 0.52

İngilizce Karşılığı

İngilizce Çevirisi: monitor **Seslendir**

Şekil 5.4.Tespit edilen nesnelerin çeviri ve seslendirilmesi

Uygulama içinde kullanıcı tarafından yüklenen fotoğrafın nesne tespiti sonuçları, fotoğrafın üst bölümündeki alanda Türkçe ve İngilizce karşılıklarıyla ayrıntılı bir şekilde sunulmaktadır. Bu bölüm, kullanıcının yüklediği fotoğraftaki nesneleri hem Türkçe hem de İngilizce olarak anlamasına yardımcı olmak amacıyla tasarlanmıştır. Ayrıca, her bir tahmin edilen nesne için doğruluk oranları da belirtilmiştir, bu sayede kullanıcıya her nesnenin tespit güvenilirliği hakkında bilgi verilmiş olur. Kullanıcının deneyimini zenginleştirmek adına eklenen bir özellik ise, kullanıcının seslendirme butonuna tıklaması durumunda, o an üzerinde durulan İngilizce kelimenin doğru telaffuzu sunulmaktadır. Bu işlem, gTTS kütüphanesi kullanılarak gerçekleştirilir ve kullanıcının İngilizce kelimenin doğru ses yapısını öğrenmesine katkı sağlar. Bu sayede, sadece yazılı değil, aynı zamanda sözlü olarak da dil becerilerini geliştirmek isteyen kullanıcılar için interaktif bir öğrenme deneyimi sunulmuş olur.

6. SONUÇ

6.1. Verileri Listeleyen Tablo

Nesne tespiti gerçekleştirildikten sonra, ilgili nesnenin sınıfı belirlenir ve bu bilgiler veritabanına kaydedilir. Ardından, bu kayıtlar geçerli kullanıcıya özgü olarak listelenip silme fonksiyonları da uygulanır. Şekil 6.1’de yer alan tablo, yüklenen fotoğrafta "gözlük" nesnesinin tespit sonucunun, veritabanına tespit zamanı ve oranıyla birlikte nesnenin ingilizce karşılığı başarılı bir şekilde kaydedildiğini göstermektedir

Nesne Adı	Çevirisi	Tespit Zamanı	Başarı Oranı	
pet sise	pet bottle	2024-01-24 19:19:55	0.69	Sil
kulaklık	headphones	2024-01-24 19:19:55	0.52	Sil
priz	socket	2024-01-24 19:34:44	0.51	Sil
cuzdan	wallet	2024-01-24 19:35:03	0.81	Sil
klavye	keyboard	2024-01-24 19:36:15	0.74	Sil
fare-ekipman-	mouse(equipment)	2024-01-24 19:36:15	0.68	Sil
sirt cantasi	backpack	2024-01-25 02:25:56	0.83	Sil
kolye	necklace	2024-01-25 15:28:22	0.66	Sil
akilli telefon	smartphone	2024-01-26 03:16:31	0.79	Sil
monitor	monitor	2024-01-26 03:17:31	0.52	Sil

Şekil 6.1.Nesne tespit tablosu

6.2. Seslendirme

Şekil 6.2’de İngilizce karşılığı butonuna tıklanıldıktan sonrasında uygulamaya entegre edilen sesli geri bildirim, kullanıcıların tespit edilen nesnelerin İngilizce karşılıklarını öğrenmelerine katkı sağlamaktadır. Bu özellik, projenin kullanıcı dostu ve etkileşimli bir deneyim sunma hedefini desteklemektedir.

Nesne Tespiti Sonucu

sirt cantasi - Güvenilirlik: 0.83

İngilizce Karşılığı

İngilizce Çevirisi: backpack

Seslendir

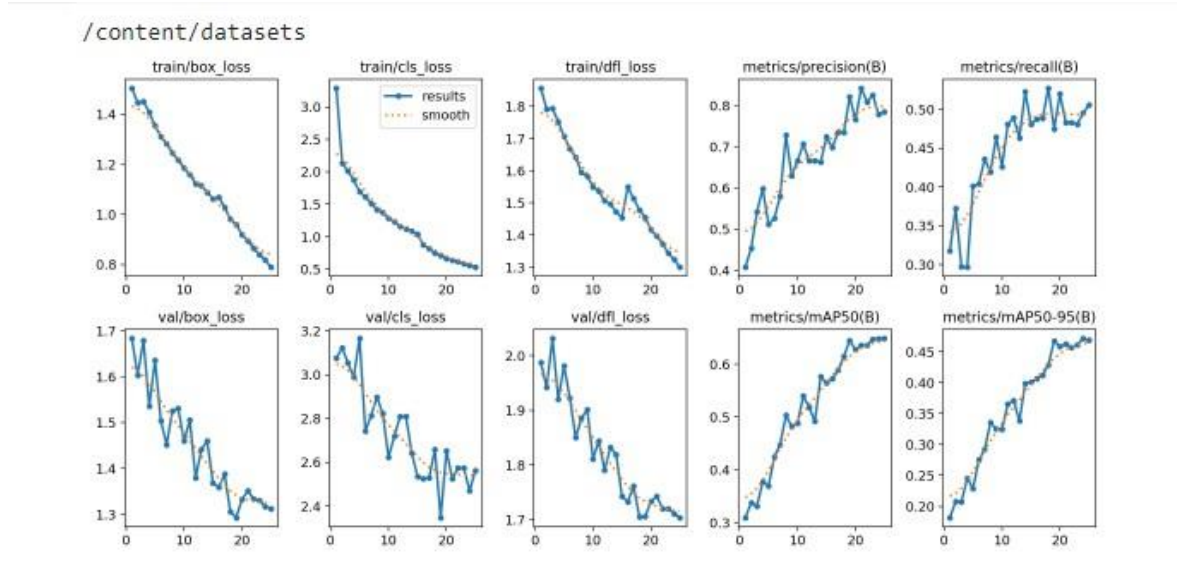
Tespit Edilen Resim:



Şekil 6.2.Nesne Tespit Sonucu

Modelin Performans Grafiği

Araştırmanın son aşamasında, modelin performansını kapsamlı bir şekilde değerlendirmek amacıyla çeşitli grafikler kullanılmıştır. Şekil 6.3'te, modelin sınıf dengesini gösteren grafikler ile başarı oranlarına yönelik detaylı görsel analizler sunulmaktadır. Bu grafikler, modelin belirli sınıflar üzerindeki tespit doğruluğunu inceleyerek, özellikle dikkat gerektiren alanları vurgulamaktadır. Performans değerlendirmesi, modelin güçlü ve zayıf yönlerini belirleme konusunda önemli bir bilgi sağlamaktadır. Bu aşamada elde edilen grafikler, modelin genel performansının yanı sıra belirli sınıflar üzerindeki performansını da detaylı bir şekilde sunmaktadır. Bu değerlendirme, modelin geliştirilmesi ve optimize edilmesi için rehberlik sağlamaktadır.



Şekil 6.3. Modelin performansını gösteren grafik

7. KAYNAKLAR

Aral, N. (2021). Öğrenme Sürecinde Görsel Algılama:Uluslararası Erken Çocukluk Eğitimi Çalışmaları Dergisi, 6(2), 43-52.

Brunetti, A., Buongiorno, D., Trotta, G., Bevilacqua, V. (2018). Computer vision and deep learning techniques for pedestrian detection and tracking: A survey. Neurocomputing,

Ciaparrone, G., Luque Sánchez, F., Tabik, S., Troiano, L.,Tagliaferri, R., Herrera, F.(2020). Deep learning in videomulti-object tracking: A survey. Neurocomputing, 61-88,

Daz R, Polat B, Tuna G (2019). Derin Öğrenme ile Resim ve Videolarda Nesnelerin Tanınması ve Takibi. Fırat Üniversitesi Mühendislik Bilimleri Dergisi 31 2 571–581.

G. Chandan, A. Jain, H. Jain and Mohana, (2018). "Real Time Object Detection and Tracking Using Deep Learning and OpenCV," 2018 International Conference on Inventive Research in Computing Applications (ICIRCA), 1305-1308.

G. Xiong, J. Qi, M. Wang, C. Wu and H. Sun (2023). "GCGE-YOLO: Improved YOLOv5s Algorithm for Object Detection in UAV Images," 2023 42nd Chinese Control Conference (CCC), 7723-7728.

Hanbay, K., & Üzen, H. (2017). Nesne tespit ve takip metotları: Kapsamlı bir derleme. Türk Doğa Ve Fen Dergisi, 6(2), 40-49.

K. Türkaslan ve F. Hardalac (2022). “Derin Öğrenme Yöntemleri Kullanılarak Havadan Elde Edilen Görüntüler Üzerinde Nesne Tespiti”, ECJSE,1398–1410.

Lu, Y., Lu, C., Tang, C. (2017). Online Video Object Detection Using Association LSTM. Proceedings of the IEEE International Conference on Computer Vision, 2344-2352.

M. Ponika, K. Jahnavi, P. S. V. S. Sridhar and K. Veena (2023). "Developing a YOLO based Object Detection Application using OpenCV," 2023 7th International Conference on Computing Methodologies and Communication (ICCMC), 662-668.

Nawaratne, R., Alahakoon, D., De Silva, D., Yu, X. (2020). Spatiotemporal anomaly detection using deep learning for real-time video surveillance. IEEE Transactions on Industrial Informatics.

Önal, O., & Dandıl, E. (2021). Object Detection for Safe Working Environments using YOLOv4 Deep Learning Model. Avrupa Bilim Ve Teknoloji Dergisi(26), 343-351.

Sevi, M., & Aydın, İ. (2023). Detection of Foreign Objects Around the Railway Line with YOLOv8. Computer Science, IDAP-2023 : International Artificial Intelligence and Data Processing Symposium(IDAP-2023), 19-23.

Tan, F. G., Yüksel, A. S., Aydemir, E., Ersoy, M. (2021). Derin Öğrenme Teknikleri İle Nesne Tespiti Ve Takibi Üzerine Bir İnceleme. Avrupa Bilim Ve Teknoloji Dergisi(25), 159-171.

Vignesh Kanna, J., Ebenezer Raj, S., Meena, M., Meghana, S., Mansoor Roomi, S. (2020). Deep Learning Based Video Analytics for Person Tracking. International Conference on Emerging Trends in Information Technology and Engineering, ic-ETITE 2020.

Yang, S., Bailey, E., Yang, Z., Ostrometzky, J., Zussman, G., Seskar, I., Kostic, Z. (2020). COSMOS Smart Intersection: Edge Compute and Communications for Bird's Eye Object Tracking. IEEE Annual Conference on Pervasive Computing and Communications Workshops (PerCom), 1-7.

Y. Ma, J. Fang, J. Zhao and Q. Zhang (2022). "Research on the Application of YOLO v3 in Railway Intruding Objects Recognition," 2022 IEEE International Conference on Artificial Intelligence and Computer Applications (ICAICA),pp. 583-5867.

Zhang, L., Gray, H., Ye, X., Collins, L., Allinson, N. (2019). Automatic individual pig detection and tracking in pig farms. Sensors (Switzerland).